



Skin Cancer

GABRIEL ARAUJO
STEVEN CABALLERO





Motivación

- Es uno de los tipos de cáncer más comunes en el mundo.
- Los algoritmos de IA pueden ayudar a los médicos a identificar lesiones malignas con mayor precisión.
- La automatización del diagnóstico permite analizar miles de imágenes en segundos.
- Contiene una gran cantidad de imágenes de lesiones en la piel etiquetadas.

¿Qué queremos lograr con este análisis?

APLICAR Y COMPARAR



Clasificar correctamente los datos, evaluando su rendimiento con métricas como accuracy, precision, recall y F1-score.

EXPLORAR ESTRUCTURAS



Mediante técnicas de clustering como KMeans y PC3 evaluando la calidad de los grupos con métricas internas.

VISUALIZACIÓN DE DATOS



Graficar y analizar visualmente los datos utilizando distintos tipos de representaciones con diagramas para facilitar su interpretación.

CLASES DE LESIONES

Abreviatura	Nombre Completo	Descripción
bkl	Benign Keratosis-like Lesions	Lesiones benignas parecidas a la queratosis, como la queratosis seborreica.
nv	Melanocytic Nev	Nevos melanocíticos o lunares, generalmente benignos.
df	Dermatofibroma	Tumor benigno de la piel, generalmente inofensivo.
vasc	Vascular Lesions	Lesiones vasculares como hemangiomas o angioqueratomas.
mel	Melanoma	Tipo de cáncer de piel maligno y agresivo.
bcc	Basal Cell Carcinoma	Carcinoma basocelular, un tipo de cáncer de piel común pero de crecimiento lento.
akiec	Actinic keratoses and intraepithelial carcinoma	Una lesión precancerosa de la piel que puede convertirse en carcinoma de células escamosas

Información del Dataset


COLUMNAS CLAVE

- lesion_id
- image_id
- dx
- dx_type
- path
- **label** "b or m"
- **image** ←



CLASES DE LESIONES

Actinic keratoses (akiec)



Basal cell carcinoma (bcc)



Benign keratosis-like lesions (bkl)



Dermatofibroma (df)



Melanoma (mel)



Melanocytic nevi (nv)



Vascular lesions (vasc)



libreria cv2

```
def load_image_cv2(path):  
    img = cv2.imread(path)  
    img = cv2.resize(img, (64, 48))  
    img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)  
    return img
```

▶ df_balanced['image'][0]

↔ ndarray (48, 64, 3) [show data](#)



Preprocessing



```
#separacion
malignos = ['mel', 'bcc', 'akiec']
df['label'] = df['dx'].apply(lambda x: 'maligno' if x in malignos else 'benigno')

from sklearn.utils import resample

benigno_df = df[df['label'] == 'benigno']
maligno_df = df[df['label'] == 'maligno']
min_size = min(len(benigno_df), len(maligno_df))

benigno_df = resample(benigno_df, replace=False, n_samples=min_size, random_state=42)
maligno_df = resample(maligno_df, replace=False, n_samples=min_size, random_state=42)
#RANDOM PERMUTATION
df_balanced = pd.concat([benigno_df, maligno_df]).reset_index(drop=True)

#guardado de imagenes
imageid_path = {os.path.splitext(os.path.basename(x))[0]: x
                 for x in glob(os.path.join(base_dir, '*', '*.jpg'))}

df_balanced['path'] = df_balanced['image_id'].map(imageid_path.get)
df_balanced['image'] = df_balanced['path'].map(load_image_cv2)

#caracteristicas
X = np.stack(df_balanced['image'].values) / 255.0 #normalizacion
y = df_balanced['label'].map({'benigno': 0, 'maligno': 1}).values
```

df_balanced['label'].value_counts()

```
count
label
benigno  1952
maligno  1952
dtype: int64
```


Modeling



```
x_train, x_test, y_train_o, y_test_o = train_test_split(X, y, test_size=0.20, random_state=999, stratify=y)
#stratify=y ayuda a la partición a separar entre clases de forma controlada
```

```
#one hot codification
y_train = to_categorical(y_train_o, num_classes = 2)
y_test = to_categorical(y_test_o, num_classes = 2)
```

```
x_train, x_validate, y_train, y_validate = train_test_split(x_train, y_train, test_size = 0.1, random_state = 999, stratify=y_train)
x_train = x_train.reshape(x_train.shape[0], *(48, 64, 3))
x_test = x_test.reshape(x_test.shape[0], *(48, 64, 3))
x_validate = x_validate.reshape(x_validate.shape[0], *(48, 64, 3))
```

Modelos S

MODEL RELU



```
#@title model ANN relu
model_ann_relu = tf.keras.Sequential([
    tf.keras.layers.Flatten(input_shape=(48, 64, 3)),
    tf.keras.layers.Dense(512, activation='relu'),
    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dense(2, activation='softmax')
])



model_ann_relu.summary()

model_ann_relu.compile(
    optimizer=tf.keras.optimizers.SGD(),
    loss='categorical_crossentropy',
    metrics=['accuracy']
)

history=model_ann_relu.fit(
    x_train, y_train,
    validation_data=(x_validate, y_validate),
    epochs=10,
    batch_size=32
)

test_loss_ann_relu, test_acc_ann_relu = model_ann_relu.evaluate(x_test, y_test)
print('Test accuracy:', test_acc_ann_relu)

plot_model_history(history)
```



Modelos S

MODEL ANN DIFFERENT





```
#@title model ANN different
model_ann_different = tf.keras.Sequential([
    tf.keras.layers.Flatten(input_shape=(48, 64, 3)),
    tf.keras.layers.Dense(2048, activation='selu'),
    tf.keras.layers.AlphaDropout(0.3),
    tf.keras.layers.Dense(512, activation='selu'),
    tf.keras.layers.AlphaDropout(0.3),
    tf.keras.layers.Dense(128, activation='selu'),
    tf.keras.layers.Dense(64, activation='selu'),
    tf.keras.layers.Dense(2, activation='softmax')
])

model_ann_different.compile(
    optimizer=tf.keras.optimizers.Nadam(),
    loss='categorical_crossentropy',
    metrics=['accuracy']
)

history=model_ann_different.fit(
    x_train, y_train,
    validation_data=(x_validate, y_validate),
    epochs=10,
    batch_size=32
)

test_loss_ann_different, test_acc_ann_different = model_ann_different.evaluate(x_test, y_test)
print('Test accuracy (ANN diferente):', test_acc_ann_different)

plot_model_history(history)
```



Modelos S



MODEL CNN

```
#@title model CONV2D
model_cnn = tf.keras.Sequential([
    tf.keras.layers.Conv2D(32, (3, 3), activation='relu', input_shape=(48, 64, 3)),
    tf.keras.layers.MaxPooling2D((2, 2)),

    tf.keras.layers.Conv2D(64, (3, 3), activation='relu'),
    tf.keras.layers.MaxPooling2D((2, 2)),

    tf.keras.layers.Conv2D(128, (3, 3), activation='relu'),
    tf.keras.layers.MaxPooling2D((2, 2)),


    tf.keras.layers.Flatten(),
    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dense(2, activation='softmax')
])

model_cnn.compile(
    optimizer=tf.keras.optimizers.Adam(),
    loss='categorical_crossentropy',
    metrics=['accuracy']
)

history=model_cnn.fit(
    x_train, y_train,
    validation_data=(x_validate, y_validate),
    epochs=35,
    batch_size=32
)

test_loss_cnn, test_acc_cnn = model_cnn.evaluate(x_test, y_test)
print('Test accuracy (CNN):', test_acc_cnn)


plot_model_history(history)
```



Modelos NS



PCA



```
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_flat)

x_train, x_test, y_train, y_test = train_test_split(X_pca, y, stratify=y, test_size=0.2)

svm_model = SVC(kernel='rbf', C=1, gamma='scale')
svm_model.fit(x_train, y_train)
y_pred_svm = svm_model.predict(x_test)

print(classification_report(y_test, y_pred_svm))
```

	precision	recall	f1-score	support
0	0.68	0.59	0.63	390
1	0.64	0.72	0.68	391
accuracy			0.66	781
macro avg	0.66	0.66	0.66	781
weighted avg	0.66	0.66	0.66	781



Modelos NS



KMEANS

```
kmeans = KMeans(n_clusters=2, random_state=42)
clusters_kmeans = kmeans.fit_predict(X_flat)


print(classification_report(y, clusters_kmeans))
```




	precision	recall	f1-score	support
0	0.48	0.49	0.48	1952
1	0.48	0.48	0.48	1952
accuracy			0.48	3904
macro avg	0.48	0.48	0.48	3904
weighted avg	0.48	0.48	0.48	3904

Modelos NS

PCA 3D




	Modelo	Accuracy	Precision	Recall
0	ANN ReLU	0.710627	0.798553	0.710974
1	ANN Diferente	0.702945	0.717210	0.703108
2	CNN	0.781050	0.781713	0.781081




Matriz de Confusión


Matriz de Confusión - ANN ReLU




Matriz de Confusión - ANN Diferente




Matriz de Confusión - CNN



Distribución de Métricas




Radar de desempeño por modelo




REDES NEURONALES CONVOLUCIONALES (CNN)

Desempeño del modelo CNN



- Especializadas en Imágenes: Detectan automáticamente patrones espaciales (bordes, texturas) usando "filtros".
- Eficientes: Reutilizan filtros en toda la imagen, reduciendo complejidad.
- Robustas: Manejan variaciones en la posición u orientación de los objetos.

Matriz de Confusión - CNN



```
El Mejor Modelo es:  
Modelo          CNN  
Accuracy        0.78105  
Precision       0.78173  
Recall          0.78105  
F1-Score        0.780927  
Combined_Score  0.781149  
Name: 2, dtype: object
```





Conclusiones

- La CNN fue el modelo supervisado más eficaz, destacando en la clasificación de imágenes de cáncer de piel gracias a su arquitectura.
- En el análisis no supervisado, PCA con SVC ofreció mejores resultados que KMEANS.
- DBSCAN mostró dificultades para formar clústeres claros, requiriendo un ajuste muy preciso de sus parámetros de densidad.

